

Otimização da Malha Logística Olist com IA

Onde automatizar sem quebrar a experiência

Relatório executivo para o COO

Base analisada: Brazilian E-Commerce Public Dataset by Olist (2016–2018)

Escopo: diagnóstico operacional, previsão de atraso, triagem de reviews, score de risco e simulação humano-máquina.

1. Resumo executivo

A Olist cresceu mais rápido do que a capacidade linear do time de operações. A pergunta de decisão não é “onde colocar IA?”, mas **onde a automação reduz trabalho repetitivo sem transferir erro, retrabalho e insatisfação para o cliente.**

A análise de pedidos, entregas e reviews indica uma recomendação em duas velocidades:

1. **Implementar primeiro a automação de triagem de reviews negativos de alta confiança.** Ela é transparente, de baixo risco e tem retorno operacional estimado positivo.
2. **Não automatizar ainda decisões individuais de intervenção logística com o modelo de atraso/score atual.** A validação temporal mostrou desempenho insuficiente: muitos alertas falsos e muitos atrasos que continuariam sem identificação.
3. **Usar IA logística inicialmente para monitoramento, aprendizado e enriquecimento de dados,** não para acionar uma fila humana cara ou prometer prevenção de atraso ao cliente.

O melhor cenário simulado é o modelo híbrido de reviews: automatizar apenas classificações de alta confiança e manter casos ambíguos para revisão humana. Esse desenho economiza **249,4 horas** no período analisado e reduz o custo total estimado de **R\$ 34.008,33 para R\$ 30.280,21**. Em contraste, automatizar 100% dos reviews reduz horas, mas cria custo oculto elevado pela má triagem de 5.433 casos ambíguos.

Decisão recomendada

Iniciativa	Decisão	Motivo
Triagem de reviews negativos	Implementar piloto híbrido	Alto volume, regras explícitas, ganho estimado e controle humano sobre ambiguidades

Mensagens automáticas de status/rastreo	Implementar com regras	Processo repetitivo e reversível; não exige confiar no modelo de atraso
Alertas de atraso por ML	Manter em monitoramento/piloto	AUC-ROC de 0,435 e precision de 4,6% não justificam fila humana
Score de risco no checkout	Não usar para intervenção humana ainda	Diferença pequena de atraso entre faixas: 6,23% vs. 5,10%
Revisão de casos de atendimento, avaria e ambíguos	Manter humano no loop	Risco reputacional, necessidade de interpretação e volume menor

2. Diagnóstico do ciclo operacional

A operação analisada reúne **99.441 pedidos**, **112.650 itens**, **99.224 reviews**, **99.441 clientes**, **3.095 vendedores** e **32.951 produtos**. Foram considerados como atraso os pedidos cuja entrega real ocorreu após a data estimada de entrega.

Indicadores principais


Indicador	Resultado
Pedidos totais	99.441
Pedidos entregues	96.456
Reviews totais	99.224
Reviews negativos, notas 1 e 2	14.575
Taxa de reviews negativos	14,69%
Tempo médio compra → entrega	12,6 dias

Mapa de processos e automação

Etapa	Evidência a analisar no dashboard	Tipo de trabalho	Decisão de automação
Compra → aprovação	Tempo entre compra e aprovação	Validações, pagamento e exceções	Automatizar regras e alertas; humano somente nas exceções de pagamento/fraude

Aprovação → postagem	Tempo até entrega à transportadora	Cobrança e acompanhamento de vendedor	Automatizar lembretes, SLA e escalonamento por regra
Postagem → entrega	Tempo de trânsito e variação por rota	Execução física e parceiros logísticos	Automatizar monitoramento e comunicação; manter intervenção humana em exceções relevantes
Pós-venda/review	Leitura, categorização e encaminhamento	Alto volume de classificação repetitiva	Automatizar triagem de alta confiança; humano em casos ambíguos/sensíveis

A oportunidade mais madura não é substituir a operação física de entrega. É reduzir trabalho repetitivo em **classificação, roteamento, lembretes e comunicação proativa**.



3. Modelo de previsão de atraso

Método

Foi construído um classificador binário para prever atraso de entrega. A validação foi temporal: os primeiros 80% dos pedidos foram usados como treino e os 20% mais recentes como teste. Essa escolha é mais rigorosa do que embaralhar a base, porque simula o cenário real: aprender com o passado e prever pedidos futuros.

Para evitar vazamento de dados, o modelo usou apenas variáveis conhecidas no checkout: estado do cliente, estado do vendedor, categoria do produto, preço total, frete total, quantidade de itens, peso, mês/dia/hora da compra e indicação de mesma UF entre vendedor e cliente.


Não foram usadas como features a data real de entrega, a data estimada de entrega, o tempo até postagem nem o tempo de aprovação, pois essas informações são posteriores ao momento de compra.

Resultado do teste temporal

Métrica	Resultado	Interpretação
AUC-ROC	0,435	A capacidade de separar atraso de não atraso é insuficiente; abaixo de 0,50 no período testado
Precision para atrasos	4,6%	A cada 100 alertas, apenas cerca de 5 eram atrasos reais
Recall para atrasos	17,3%	O modelo identificou 177 dos 1.021 atrasos reais
F1-score	7,3%	Equilíbrio baixo entre precisão e cobertura
Baseline: prever sempre “no prazo”	Recall 0,0%	Baseline não encontra nenhum atraso; accuracy seria enganosa por atraso ser minoria

Matriz de confusão

Resultado	Quantidade
Verdadeiros negativos: no prazo previsto corretamente	14.606
Falsos positivos: alerta desnecessário	3.669
Falsos negativos: atraso não detectado	844
Verdadeiros positivos: atraso detectado	177



Decisão

O modelo não deve disparar intervenção humana individual nesta fase. Uma operação baseada nele enviaria 3.846 alertas ao time, mas 3.669 seriam falsos positivos. Isso significa custo, fadiga operacional e perda de confiança nos alertas, enquanto 844 atrasos ainda passariam sem ação.

O resultado não é um fracasso do projeto; é uma evidência contra “IA por moda”. Com as variáveis disponíveis no checkout, a base não sustenta decisão automatizada de alto custo. A recomendação é enriquecer o dado antes de reavaliar o modelo.

Dados necessários para evoluir

- Transportadora e modalidade de frete
- CEP/faixa de CEP de origem e destino, distância e região logística
- SLA contratado e data prometida no checkout
- Estoque disponível e tempo de separação
- Histórico do vendedor: despacho, cancelamento e cumprimento de SLA
- Eventos de rastreamento da transportadora
- Capacidade/sazonalidade operacional por região

4. Triagem automática de reviews negativos

Método


Foram selecionadas as **14.575 reviews com nota 1 ou 2**. Dessas, 10.987 continham texto, equivalentes a 75,4% do total negativo. Foi implementado um classificador transparente baseado em regras e palavras-chave em português, com cinco saídas: prazo/entrega, produto, atendimento, embalagem/avaria e outros/sem classificação.

A técnica foi escolhida pelo custo-benefício do piloto: não requer API externa, GPU, fine-tuning ou dados rotulados; é auditável e permite que operações veja por que cada review foi roteada. O arquivo `amostra_para_validacao_manual.csv` permite validar e melhorar as regras com revisão humana.

Distribuição dos temas

Tema	Reviews	Percentual	Ação recomendada
Outros / sem classificação	5.433	37,3%	Revisão humana e uso como base para melhorar o classificador
Prazo / entrega	4.361	29,9%	Roteamento automático para rastreio, SLA e comunicação proativa
Produto	4.171	28,6%	Roteamento automático para vendedor, troca, qualidade ou catálogo
Atendimento	439	3,0%	Manter humano no loop; impacto reputacional alto
Embalagem / avaria	171	1,2%	Fila específica e análise de recorrência por vendedor/transportadora

Prazo/entrega e produto somam **8.532 reviews**, ou **58,5%** de todas as avaliações negativas. Esse é o principal espaço de produtividade: roteamento inicial automático, com regras claras e auditoria por amostragem.



Confiança operacional

Nível de confiança	Reviews	Tratamento
Alta	3.990	Pode ser roteada automaticamente no piloto
Média	5.152	Manter em amostra auditada antes de ampliar automação
Baixa	5.433	Revisão humana obrigatória

A classificação não deve “fingir certeza”. Casos sem palavra-chave ou com texto ausente permanecem na fila humana, preservando qualidade e permitindo aprendizado contínuo.


5. Score de risco e equilíbrio humano-máquina

Score de risco por pedido

Foi criado um score explicável de 0 a 100 baseado em risco histórico por rota vendedor-cliente, risco por categoria, envio para outra UF, peso, frete e quantidade de itens. O score foi calculado para 19.888 pedidos posteriores ao corte temporal de 24/05/2018, usando 76.981 pedidos anteriores como histórico.

Faixa	Pedidos	Percentual	Score médio	Atrasos reais	Taxa real de atraso
Baixo — fluxo automatizado	19.086	96,0%	17,1	973	5,10%
Médio — monitoramento automático	802	4,0%	32,4	50	6,23%
Alto / crítico	0	0,0%	—	—	—


A diferença entre as faixas foi de apenas **1,13 ponto percentual** na taxa real de atraso. Portanto, o score é útil como artefato de monitoramento e transparência, mas ainda não oferece separação suficiente para justificar uma fila humana de alto custo.



Simulação de triagem de reviews

Hipóteses explícitas da simulação: 4 minutos por review na triagem manual, 0,25 minuto por review automatizada e custo operacional de R\$ 35/hora. Custos de erro são proxies e devem ser substituídos por custos reais da Olist antes de produção.

Cenário	Horas operacionais	Horas poupadas	Falsos negativos estimados	Custo total estimado
100% manual	971,7	0,0	0	R\$ 34.008,33
100% automático	60,7	910,9	5.433	R\$ 137.950,52
Híbrido: somente alta confiança	722,3	249,4	200	**R\$ 30.280,21**
Híbrido: alta + média; humano na baixa	400,3	571,4	972	R\$ 38.310,21



Recomendação de equilíbrio

O melhor cenário financeiro do piloto é automatizar apenas as 3.990 reviews de alta confiança e manter 10.585 reviews para humano. Ele poupa 249,4 horas e reduz o custo total estimado em R\$ 3.728,12 versus a operação totalmente manual.

Automatizar 100% é o pior desenho: reduz horas, mas o custo estimado sobe para R\$ 137.950,52 porque 5.433 casos ambíguos deixam de receber o tratamento correto. Já automatizar alta e média confiança economiza mais horas, porém gera mais erros estimados e custo total superior ao processo manual.

A automação paga o próprio investimento quando atua em decisões repetitivas, reversíveis e auditáveis. O humano se paga em exceções, ambiguidades e temas de maior dano reputacional.

6. Portfólio priorizado e roadmap de 90 dias

Priorização

Automação	Impacto esperado	Esforço	Risco	Prioridade
Triagem de reviews de alta confiança	Alto	Baixo	Baixo	1
Roteamento de prazo/entrega e produto	Alto	Médio	Baixo-médio	2
Alertas automáticos de SLA/postagem ao vendedor	Médio-alto	Baixo	Baixo	3
Painel de exceções e auditoria de reviews	Médio	Baixo	Baixo	4
Enriquecimento de dados logísticos	Alto	Médio-alto	Baixo	5
Novo modelo de atraso com dados enriquecidos	Alto potencial	Alto	Médio	6
Intervenção humana automática baseada em score	Incerto	Médio	Alto	Não priorizar agora

Roadmap

Dias 0–30: piloto controlado

- Publicar a triagem por regras para reviews de alta confiança.
- Criar filas separadas para prazo/entrega e produto.
- Manter humano para atendimento, avaria e baixa confiança.

- Auditar semanalmente uma amostra de 100 classificações automáticas.
- Medir tempo médio de triagem, taxa de reencaminhamento e taxa de erro.

Dias 31–60: integração e aprendizagem

- Integrar o roteamento ao fluxo de atendimento/CX.
- Criar respostas-modelo e comunicações de status para problemas de prazo.
- Identificar palavras-chave novas a partir de “outros/sem classificação”.
- Conectar dados de transportadora, rastreo e SLA à base analítica.
- Criar dashboard de volume, temas, backlog e tempo de resolução.

Dias 61–90: escala com governança

- Expandir automação para parte das reviews de confiança média somente se a auditoria indicar qualidade aceitável.
- Recalibrar o classificador de atraso com novos dados logísticos.
- Definir thresholds com custo real por falso positivo, falso negativo e intervenção humana.
- Rodar A/B test: fluxo atual versus fluxo de triagem assistida.
- Só então avaliar uso do score para priorização limitada de casos críticos.

KPIs de acompanhamento

- Horas de triagem por mil reviews
- Percentual de reviews roteadas automaticamente
- Taxa de reencaminhamento/reclassificação humana
- Tempo até primeira resposta ao cliente
- Backlog de reviews negativas
- Taxa de atraso por rota, vendedor, categoria e transportadora
- Precision e recall do novo modelo de atraso
- NPS/CSAT e taxa de recompra após tratamento de reclamações

Conclusão

A análise demonstra que produtividade com IA não vem de automatizar todo o processo. Ela vem de selecionar tarefas repetitivas, mensuráveis e reversíveis, preservando pessoas para exceções e decisões de maior impacto.

Para a Olist, a decisão é objetiva: **começar por triagem inteligente de reviews de alta confiança e comunicação operacional; não escalar ainda um modelo de atraso fraco para uma fila humana.** O próximo ganho dependerá menos de um algoritmo mais complexo e mais de dados logísticos melhores, governança de métricas e ciclos de validação com a operação.

Anexo: arquivos produzidos

```
01_exploracao.py
02_modelo_atraso.py
03_nlp_reviews.py
04_score_risco.py
05_simulacao_humano_maquina.py
```

```
outputs/
├── diagnostico_etapas.csv
├── atraso_mensal.csv
├── atraso_por_estado.csv
├── base_pedidos_modelagem.csv
├── graficos/
├── modelo_atraso/
├── nlp_reviews/
├── score_risco/
└── simulacao_humano_maquina/
```